

第 12 周 充分统计量

二、充分统计量

2.1 定义（不损失任何关于参数 θ 的信息）

样本中包含的关于总体的信息可分为两部分：其一是关于总体结构的信息，即反映总体分布的结构；其二是关于总体中未知参数的信息。统计量具有压缩数据功能，一个好的统计量应该能将样本中包含未知参数的全部信息提取出来，这种不损失未知参数的信息的统计量就是我们要介绍的充分统计量。

★ 充分统计量的定义如下：设 $X_1, X_2, \dots, X_n$ 是总体 X 的简单样本，总体分布函数为 $F(x, \theta)$ ，称统计量 $T = T(X_1, X_2, \dots, X_n)$ 为 θ 的充分统计量，如果在给定 T 的取值后， $X_1, X_2, \dots, X_n$ 的条件分布与 θ 无关。

★ 定理 A:

若样本 $X_1, X_2, \dots, X_n$ 的联合分布密度（或 p.m.f）为 $f(x_1, x_2, \dots, x_n | \theta)$ ，统计量 $T = T(X_1, X_2, \dots, X_n)$ 的分布密度（或 p.m.f）为 $q(t | \theta)$ ，则若

$\frac{f(x_1, x_2, \dots, x_n | \theta)}{q(T(x_1, x_2, \dots, x_n) | \theta)}$ 与 θ 无关，则 $T = T(X_1, X_2, \dots, X_n)$ 为充分统计量。

例（离散情形）设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim B(1, \theta), 0 < \theta < 1$ （即 **Bernoulli**

分布）的一个样本，证明 $T = \sum_{i=1}^n X_i$ 为 θ 的充分统计量

用定义证明：只需证明 $P(X_1 = x_1, \dots, X_n = x_n | T = t)$ 与 θ 无关，这里 $x_i = 0, 1$ ，

$t = \sum_{i=1}^n x_i$ （否则，概率为 0），由于 $T = \sum_{i=1}^n X_i \sim B(n, \theta)$

$$P(X_1 = x_1, \dots, X_n = x_n | T = t) = \frac{P(X_1 = x_1, \dots, X_n = x_n, T = t)}{P(T = t)}$$

$$= \frac{P(X_1 = x_1, \dots, X_{n-1} = x_{n-1}, X_n = t - \sum_{i=1}^{n-1} x_i)}{P(T = t)}$$

$$= \frac{\prod_{i=1}^{n-1} [\theta^{x_i} (1-\theta)^{1-x_i}] \cdot \theta^{t - \sum_{i=1}^{n-1} x_i} (1-\theta)^{1 - (t - \sum_{i=1}^{n-1} x_i)}}{C_n^t \theta^t (1-\theta)^{n-t}} = \frac{1}{C_n^t}$$

例(连续情形) 设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim N(\mu, 1)$ 的一个样本, 证明 $T = \bar{X}$ 为 μ 的充分统计量

解: 利用定理 A 证明 (利用定义也可以证明, 见教材):

$X_1, X_2, \dots, X_n$ 的联合分布密度为

$$\begin{aligned} f(x_1, x_2, \dots, x_n | \mu) &= \prod_{i=1}^n f(x_i; \mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_i - \mu)^2}{2}} \\ &= \left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2}} \\ T = \bar{X} \sim N\left(\mu, \frac{1}{n}\right) \text{ 的分布密度为 } q(t | \mu) &= \frac{1}{\sqrt{\frac{2\pi}{n}}} e^{-\frac{(t - \mu)^2}{2 \cdot \frac{1}{n}}}, \text{ 故} \end{aligned}$$

$$\begin{aligned} &\frac{f(x_1, x_2, \dots, x_n | \mu)}{q(T(x_1, x_2, \dots, x_n) | \mu)} \\ &= \frac{\left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2}}}{\frac{1}{\sqrt{\frac{2\pi}{n}}} e^{-\frac{(\bar{x} - \mu)^2}{2 \cdot \frac{1}{n}}}} \\ &= n^{-\frac{1}{2}} (2\pi)^{-\frac{n-1}{2}} e^{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2}} \end{aligned}$$

与 μ 无关, 故 $T = \bar{X}$ 为 μ 的充分统计量。

例 设 X_1, X_2 是总体 $X \sim P(\lambda)$ 的一个样本, 证明 $T_1 = X_1 + X_2$ 为 λ 的充分统计量, 而 $T_2 = X_1 + 2X_2$ 不是 λ 的充分统计量。

解:

$$P(X_1 = x_1, X_2 = x_2 | T_1 = t) = \begin{cases} \frac{P(X_1 = x_1, X_2 = t - x_1)}{P(T_1 = t)} = \frac{\frac{\lambda^{x_1} e^{-\lambda}}{x_1!} \frac{\lambda^{t-x_1} e^{-\lambda}}{(t-x_1)!}}{\frac{(2\lambda)^t e^{-2\lambda}}{t!}} = \frac{C_t^{x_1}}{2^t}, & t = x_1 + x_2, x_1, x_2 = 0, 1, 2, \dots \\ 0, & \text{otherwise} \end{cases}$$

与 λ 无关, 故 $T_1 = X_1 + X_2$ 为 λ 的充分统计量。

$$\begin{aligned} P(X_1 = 0, X_2 = 1 | T_2 = 2) &= P(X_1 = 0, X_2 = 1 | X_1 + 2X_2 = 2) \\ &= \frac{P(X_1 = 0, X_2 = 1)}{P(X_1 + 2X_2 = 2)} \\ &= \frac{P(X_1 = 0, X_2 = 1)}{P(X_1 = 0, X_2 = 1) + P(X_1 = 2, X_2 = 0)} \\ &= \frac{e^{-\lambda} \lambda e^{-\lambda}}{e^{-\lambda} \lambda e^{-\lambda} + \frac{\lambda^2 e^{-\lambda}}{2!} e^{-\lambda}} = \frac{2}{2 + \lambda} \end{aligned}$$

依赖于 λ , 故 $T_2 = X_1 + 2X_2$ 不是 λ 的充分统计量。

如何寻找充分统计量?

★ 定理 B: (因子分解定理) 总体概率函数 $f(x, \theta)$, 样本 $(X_1, \dots, X_n)$, 统计量

$T(X_1, \dots, X_n)$ 为未知参数 θ 的充分统计量的充要条件是样本在已发生情形

$(X_1, \dots, X_n) \rightarrow (x_1, \dots, x_n)$ 处的联合概率函数可以分解为 $T(x_1, \dots, x_n) = t$ 和 θ 的函

数 $g(t, \theta)$ 与样本观察值的函数 $h(x_1, \dots, x_n)$ 的乘积。

即: T 是 θ 的充分统计量

$$\Leftrightarrow L(\theta) = \prod_{i=1}^n f(x_i; \theta) = h(x_1, x_2, \dots, x_n) g(T(x_1, x_2, \dots, x_n); \theta) \text{ 且 } h \text{ 非负}$$

定理证明: 只就离散情况证明, 必要性 $\Rightarrow$

$$P(X_1 = x_1, \dots, X_n = x_n | T = t) \stackrel{T(x_1, \dots, x_n) = t}{=} h(x_1, \dots, x_n) \text{ 与 } \theta \text{ 无关,}$$

由于 $\{T = t\} \supset \{X_1 = x_1, \dots, X_n = x_n\}$

因此 $P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1, \dots, X_n = x_n | T = t) P(T = t)$

$$= h(x_1, \dots, x_n) P(T = t) = g(t, \theta) h(x_1, \dots, x_n)$$

充分性 $\Leftarrow$

现在已知 $P(X_1 = x_1, \dots, X_n = x_n) = g(t, \theta)h(x_1, \dots, x_n)$

$$\begin{aligned} P(T=t) &= \sum_{T(x_1, \dots, x_n)=t} P(X_1 = x_1, \dots, X_n = x_n) \\ &= \sum_{T(x_1, \dots, x_n)=t} g(t, \theta)h(x_1, \dots, x_n) = g(t, \theta) \sum_{T(x_1, \dots, x_n)=t} h(x_1, \dots, x_n) \end{aligned}$$

$$\begin{aligned} \text{因此 } P(X_1 = x_1, \dots, X_n = x_n | T=t) &= \frac{P(X_1 = x_1, \dots, X_n = x_n, T=t)}{P(T=t)} \\ &= \frac{P(X_1 = x_1, \dots, X_n = x_n, T=t)}{g(t, \theta) \sum_{T(x_1, \dots, x_n)=t} h(x_1, \dots, x_n)} = \frac{P(X_1 = x_1, \dots, X_n = x_n)}{g(t, \theta) \sum_{T(x_1, \dots, x_n)=t} h(x_1, \dots, x_n)} \\ &= \frac{P(X_1 = x_1, \dots, X_n = x_n, T=t)}{g(t, \theta) \sum_{T(x_1, \dots, x_n)=t} h(x_1, \dots, x_n)} = \frac{P(X_1 = x_1, \dots, X_n = x_n)}{g(t, \theta) \sum_{T(x_1, \dots, x_n)=t} h(x_1, \dots, x_n)} \\ &= \frac{g(t, \theta)h(x_1, \dots, x_n)}{g(t, \theta) \sum_{T(x_1, \dots, x_n)=t} h(x_1, \dots, x_n)} = \frac{h(x_1, \dots, x_n)}{\sum_{T(x_1, \dots, x_n)=t} h(x_1, \dots, x_n)} \text{ 与 } \theta \text{ 无关} \end{aligned}$$

★推论：设统计量 T 为 θ 的充分统计量，统计量 S 与 T 一一对应，则 S 也为 θ 的充分统计量。

例 设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim B(1, \theta), 0 < \theta < 1$ （即 **Bernoulli** 分布），证

明 $T = \sum_{i=1}^n X_i$ 为 θ 的充分统计量

解：用因子分解证明：样本的分布为

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n [\theta^{x_i} (1-\theta)^{1-x_i}] = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i}$$

取

$$h(x_1, x_2, \dots, x_n) = 1,$$

$$g(T(x_1, x_2, \dots, x_n); \theta) = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i}$$

故 $T = \sum_{i=1}^n X_i$ 为 θ 的充分统计量。

注：显然 $T_1 = (X_1, X_2 + \dots + X_n)$ 、 $T_2 = (X_1 + X_2, X_3, X_4 + \dots + X_n)$ 也是 θ 的充分统计

量（不唯一）。

例 设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim N(\mu, \sigma^2)$ 的一个样本, μ, σ^2 均未知, 求 (μ, σ^2) 的充分统计量。

解: 样本的分布密度为

$$\begin{aligned} f_{\mu, \sigma^2}(x_1, x_2, \dots, x_n) &= \prod_{i=1}^n f(x_i; \mu, \sigma^2) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \\ &= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{\sum_{i=1}^n x_i^2}{2\sigma^2} + \frac{\mu \sum_{i=1}^n x_i}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}} \end{aligned}$$

故 $T = T(X_1, X_2, \dots, X_n) = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ 为 (μ, σ^2) 的充分统计量

注: 显然 $T_1 = (\bar{X}, S^2)$ 为 (μ, σ^2) 的充分统计量, 这个一般更常用。若 σ^2 未知, $\bar{X}$ 不是 μ 的充分统计量; μ 未知时, S^2 也不是 σ^2 的充分统计量。但若 σ^2 已知, $\bar{X}$ 是 μ 的充分统计量, $\mu = \mu_0$ 已知, $\sum_{i=1}^n (X_i - \mu_0)^2$ 是 σ^2 的充分统计量。

例 设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim U(-\frac{\theta}{2}, \frac{\theta}{2})$ 的一个样本, , 求参数 θ 的充分统计量。

解: 样本的分布密度为

$$\begin{aligned} f(x_1, x_2, \dots, x_n) &= \prod_{i=1}^n f(x_i; \theta) = \frac{1}{\theta^n} 1_{\{-\frac{\theta}{2} < x_1, \dots, x_n < \frac{\theta}{2}\}} \\ &= \frac{1}{\theta^n} 1_{\{-\frac{\theta}{2} < x_{(1)} \leq x_{(n)} < \frac{\theta}{2}\}} \end{aligned}$$

故 $(X_{(1)}, X_{(n)})$ 为 θ 的充分统计量。当然全样本 $(X_1, X_2, \dots, X_n)$ 记顺序统计量 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 也是 θ 的充分统计量。

三. 参数点估计

★ 问题的提出：参数估计的意义.

1 点估计

$\theta = \theta(X_1, X_2, \dots, X_n)$ 点估计量

$\theta = \theta(x_1, x_2, \dots, x_n)$ 点估计值

1.2. 矩估计与极大似然估计

★ 矩估计：用样本矩作为总体矩估计

★ 极大似然估计：使得似然函数达到极大， $L(x_1, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, \dots, x_n; \theta)$.

★ 矩估计法：

1) 出发点；

★ $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} EX^k = \mu_k, k \geq 1$

2) 方法与步骤

① 求出总体的 k 阶原点矩： $a_k = EX^k = \int_{-\infty}^{+\infty} x^k dF(x; \theta_1, \theta_2, \dots, \theta_m)$

② 解方程组 $a_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ ($k=1, 2, \dots, m$)，得 $\theta_k = \theta_k(X_1, X_2, \dots, X_n)$ 即为所求

★ 极大似然估计法：

1) 出发点； 实际推断原则（似然函数达到极大）

★ 似然函数 $L(x_1, \dots, x_n; \theta) = \begin{cases} \prod_{i=1}^n P(X = x_i), \\ \prod_{i=1}^n f(x, \theta) \end{cases}$

2) 方法与步骤

① 写出似然函数 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ ，求出 $\ln L$ 及似然方程 $\left. \frac{\partial \ln L}{\partial \theta_i} \right|_{\theta=\theta} = 0$

$i=1, 2, \dots, m$

② 解似然方程得到 $\theta_i(x_1, x_2, \dots, x_n)$ ，即极大似然估计 $\theta_i(X_1, X_2, \dots, X_n)$

$i=1, 2, \dots, m$

注：似然方程无解时，求出 θ 的定义域中使得似然函数最大的值，即为最大似然

估计。

例 设 $X \sim B(1, p)$. $X_1, X_2, \dots, X_n$ 是来自 X 的一个样本, 试求参数 p 的矩估计量

$$\hat{p}_M$$

例 设 $X \sim f(x) = \begin{cases} \frac{6x}{\theta^3}(\theta - x) & 0 < x < \theta \\ 0 & \text{else} \end{cases}$,

求 1). θ 的矩估计量 $\hat{\theta}$, 2). 求 $\hat{\theta}$ 的方差. 【 $2\bar{X}$; $\frac{\theta^2}{5n}$ 】

例

设总体 X 的概率密度为 $f(x) = \begin{cases} e^{-(x-\theta)} & x \geq \theta \\ 0 & x < \theta \end{cases}$, 而 $X_1, X_2, \dots, X_n$ 是来自总体 X 的

简单随机样本, 求未知参数 θ 的矩估计量 【 $\bar{X} - 1$ 】

例 设总体 X 的概率分布为

$$X \sim \begin{pmatrix} 0 & 1 & 2 & 3 \\ \theta^2 & 2\theta(1-\theta) & \theta^2 & 1-2\theta \end{pmatrix}$$

其中 $\theta (0 < \theta < \frac{1}{2})$ 是未知参数, 利用总体 X 的如下样本值

3, 1, 3, 0, 3, 1, 2, 3,

求 θ 的矩估计值和最大似然估计值. 【 $1/4$; $\frac{7-\sqrt{13}}{12}$ 】

例 设总体 X 的概率密度为

$$f(x; \theta) = \begin{cases} \theta, & 0 < x < 1, \\ 1-\theta, & 1 \leq x < 2, \\ 0, & \text{其他}, \end{cases}$$

其中 θ 是未知参数 ($0 < \theta < 1$), $X_1, X_2, \dots, X_n$ 为来自总体 X 的简单随机样本, 记 N

为样本值 $x_1, x_2, \dots, x_n$ 中小于 1 的个数, 求 θ 的最大似然估计. 【 $\hat{\theta} = \frac{N}{n}$ 】

例 设总体 X 的二阶矩存在, $X_1, X_2, \dots, X_n$ 为其样本. 求 X 的期望 μ 和方差 σ^2 的

矩估计量 $\hat{\mu}_M$ 和 $\hat{\sigma}_M^2$; 又若 X 为正态, 求最大似然估计量 $\hat{\mu}_L$ 和 $\hat{\sigma}_L^2$.

例 设总体 $X \sim U[0, \theta]$, $\theta (> 0)$ 未知, $X_1, X_2, \dots, X_n$ 是一个样本, 试求 θ 的矩估计

量 $\hat{\theta}_M$ 和最大似然估计量 $\hat{\theta}_L$.

$$\text{【 } \hat{\theta}_M = 2\bar{X}, \hat{\theta}_L = X_{(n)} \text{】}$$

【矩估计法：易知 $E(X) = \frac{\theta}{2}$ ，建立方程 $\frac{\theta}{2} = \bar{X} \Rightarrow \hat{\theta}_M = 2\bar{X}$ 。

最大似然估计法： $L(x_1, \dots, x_n; \theta) = \begin{cases} \theta^{-n}, & 0 \leq x_i \leq \theta, \quad i=1,2,\dots,n \\ 0, & \text{其他.} \end{cases}$ ；由似然函数可

以看出，要使 $L(x_1, \dots, x_n; \theta)$ 最大，就要使 θ 尽可能地小，但 θ 又不能小于

$x_{(n)} = \max\{x_1, \dots, x_n\}$ ，所以， θ 取 $x_{(n)} = \max\{x_1, \dots, x_n\}$ 时就使 $L(x_1, \dots, x_n; \theta)$ 达到最

大，故 $\hat{\theta}_L = X_{(n)}$ 】

例 设总体 X 的概率密度函数为 $f(x) = \begin{cases} \lambda e^{-\lambda(x-\mu)} & \text{当 } x > \mu \\ 0 & \text{当 } x \leq \mu \end{cases}$ ，这里 μ 和 $\lambda (>0)$

都是参数。又设 $X_1, X_2, \dots, X_n$ 为该总体的简单样本，而 $x_1, x_2, \dots, x_n$ 为其样本观察值。

1) 设 λ 已知，求 μ 的极大似然估计 $\hat{\mu}_L$ 。

$$\text{【 } \min(x_1, x_2, \dots, x_n) \text{】}$$

2) 设 μ 已知，求 λ 的矩估计 $\hat{\lambda}_M$ 。

$$\text{【 } (\bar{x} - \mu)^{-1} \text{】}$$

例 设总体的分布函数为

$$F(x; \lambda, \theta) = \begin{cases} 0, & \text{当 } x \leq \theta, \\ 1 - (\theta/x)^\lambda, & \text{当 } \theta < x. \end{cases}$$

其中 $\theta > 0, \lambda > 0$ 都是未知参数。设 $X_1, \dots, X_n$ 为简单样本，求 θ 和 λ 的极大似然估计。

2. 点估计的评价标准

点估计与优良性：概念、无偏估计、均方误差准则、相合估计(一致估计)、渐近正态估计

★ 无偏性： θ 的估计量 $\hat{\theta}(x_1, \dots, x_n)$ 满足 $E\hat{\theta} < +\infty$ ，且 $\forall \theta \in \Theta$ ，有 $E\hat{\theta} = \theta$ ，称 $\hat{\theta}$ 为 θ 的无偏估计量。

★ θ 的均方误差： $MSE(\theta, \theta) = E(\theta - \theta)^2 = D\theta + (E\theta - \theta)^2 = D(\hat{\theta}) + (Bias(\hat{\theta}))^2$

若 θ 是无偏估计，则 $MSE(\theta, \theta) = D\theta$

★ 有效性: 对于 θ 的无偏估计量 θ_1, θ_2 , 若对于任意的 $\theta \in \Theta$ 有

$$D(\theta_1) \leq D(\theta_2),$$

且至少有一个 $\theta \in \Theta$ 使得上述不等式严格成立, 则称 θ_1 比 θ_2 有效。

★ 性质

☆ 设总体 X 的 k 阶矩 $\mu_k = EX^k$, $k \geq 1$ 存在. 又设 $X_1, X_2, \dots, X_n$ 是 X 的一个样本.

试证明不论总体服从什么分布, k 阶样本矩 $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 一定是 k 阶总体矩 μ_k 的

无偏估计. 样本方差 S^2 一定是总体方差的无偏估计。

☆ 对正态总体 $N(\mu, \sigma^2)$, 若 μ 和 σ^2 均为未知, 则

(1) μ 的矩估计量和最大似然估计量 $\bar{X}$ 是无偏的;

(2) σ^2 的矩估计量和最大似然估计量 $\hat{\sigma}^2 = S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是有偏的;

(3) $S^2 = \frac{n}{n-1} S_n^2$, 即 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 是 σ^2 的无偏估计量.

例 设 $X \sim U[0, \theta]$, 参数 θ 未知, $X_1, X_2, \dots, X_n$ 是其大小为 n 的样本. 则

1) 矩估计量 $\hat{\theta}_M = 2\bar{X}$ 是无偏的;

2) 似然估计 $\hat{\theta}_L = X_{(n)} = \max\{X_1, X_2, \dots, X_n\}$, 不是参数 θ 的无偏估计. 但

$\frac{n+1}{n} \hat{\theta}_L = \frac{n+1}{n} X_{(n)}$ 是比 $\hat{\theta}_M = 2\bar{X}$ 有效的估计量.

3) 求 $n(\theta - \hat{\theta}_L)$ 的极限分布.

【参数为 $1/\theta$ 的指数分布】

例 设 $X_1, X_2, \dots, X_n (n > 2)$ 为来自总体 $N(0, \sigma^2)$ 的简单随机样本, $\bar{X}$ 为样本均值,

记 $Y_i = X_i - \bar{X}, i = 1, 2, \dots, n$.

求: (I) Y_i 的方差 $DY_i, i = 1, 2, \dots, n$;

【 $\frac{n-1}{n}$ 】

(II) Y_1 与 Y_n 的协方差 $Cov(Y_1, Y_n)$.

【 $-\frac{1}{n}$ 】

(III)若 $c(Y_1 + Y_n)^2$ 为 σ^2 的无偏估计量, 求参数 c .

【 $\frac{n}{2(n-2)}$ 】

例 设总体 X 服从 $\text{Ex}(\lambda)$, 未知参数 $\lambda = 1/\theta > 0$, pdf 为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0, \\ 0, & \text{其它}, \end{cases}$$

又设 $X_1, X_2, \dots, X_n$ 是来自 X 的样本, 试证

1) $\bar{X}$ 和 $nX_{(1)}$ 都是 θ 的无偏估计量, 其中 $X_{(1)} = \min\{X_1, X_2, \dots, X_n\}$.

2) 当 $n > 1$ 时, 对于 θ 的估计, $\bar{X}$ 较 $nX_{(1)}$ 有效.

★ 相合性: $\forall \theta \in \Theta, \hat{\theta}_n(x_1, \dots, x_n) \xrightarrow{P} \theta$, 则称 θ_n 为 θ 的相合估计 (一致估计)

注: 相合性要求是最基本的要求, 不满足相合性的估计一般不予考虑.

★ 理论依据和方法: 大数定律、依概率收敛的性质
进一步的判断依据

定理 A: 若 $\lim_{n \rightarrow \infty} E\theta_n = \theta$ 且 $\lim_{n \rightarrow \infty} D\theta_n = 0$, 则 θ_n 为 θ 的相合估计.

定理 B: 若 $\hat{\theta}_n^1, \hat{\theta}_n^2, \dots, \hat{\theta}_n^k$ 分别为 $\theta_1, \theta_2, \dots, \theta_k$ 的相合估计, $\eta = g(\theta_1, \theta_2, \dots, \theta_k)$ 是 $\theta_1, \theta_2, \dots, \theta_k$ 的连续函数, 则 $g(\hat{\theta}_n^1, \hat{\theta}_n^2, \dots, \hat{\theta}_n^k)$ 为 $g(\theta_1, \theta_2, \dots, \theta_k)$ 的相合估计.

例 设 $X \sim U[0, \theta]$, 参数 θ 未知, $X_1, X_2, \dots, X_n$ 是其容量为 n 的样本. 则

其最大似然估计 $\hat{\theta}_L = X_{(n)} = \max\{X_1, X_2, \dots, X_n\}$ 是 θ 的相合估计.

$$\text{解: } E(\hat{\theta}_L) = E[\max\{X_1, X_2, \dots, X_n\}] = \frac{n}{n+1} \theta \rightarrow \theta$$

$$D(\hat{\theta}_L) = \frac{n}{n+2} \theta^2 - \left[\frac{n}{n+1} \theta\right]^2 = \frac{n}{(n+1)^2(n+2)} \theta^2 \rightarrow 0$$

故 $\hat{\theta}_L = X_{(n)} = \max\{X_1, X_2, \dots, X_n\}$ 是 θ 的相合估计.