

第 13 周讲稿 UMVUE 和有效估计

UMVUE 和有效估计

★ θ^* 是 θ 的无偏估计, 若对于 θ 的任意一个无偏估计量 θ , 有 $D\theta^* \leq D\theta$, 则 θ^* 是 θ 的最小方差无偏估计, 记 MVUE 或 UMVUE (uniformly minimum-variance unbiased estimator)

注: 这里一致是指 $\forall \theta \in \Theta$ 。

★ 重要的定理 (Rao-Blackwell 定理)

定理: 随机变量 X 的方差存在, 令 $\varphi(Y) = E(X | Y)$, 则

$$E[\varphi(Y)] = EX, D[\varphi(Y)] \leq DX$$

且等号成立当且仅当 $P(X = \varphi(Y)) = 1$ 。

证明: 不妨设 $EX = 0$, 则

$$\begin{aligned} D[\varphi(Y)] &= E[\varphi(Y)]^2 \\ &= E[E(X | Y)]^2 \\ &= E\{[E(X | Y)][E(X | Y)]\} \\ &= E[E(XE(X | Y) | Y)] \\ &= E(XE(X | Y)) \\ &\leq \sqrt{EX^2 E[E(X | Y)]^2} \end{aligned}$$

从而 $D[\varphi(Y)] = E[E(X | Y)]^2 \leq EX^2 = DX$

注: 可以直接利用 $DX = D[E(X | Y)] + E[D(X | Y)]$ 。

★ 推论: 若 $T = T(X_1, X_2, \dots, X_n)$ 为 θ 的充分统计量, $\hat{\theta}$ 为 θ 的任一无偏估计量, 则 $\tilde{\theta} = E(\hat{\theta} | T)$ 也为 θ 的无偏估计量, 且 $D(\tilde{\theta}) \leq D\hat{\theta}$ 。

例: 设 $X_1, X_2, \dots, X_n$ 是总体 $X \sim B(1, p), 0 < p < 1$ (即 Bernoulli 分布) 的一个样本, 显然估计量 X_1 是 p 的无偏估计。我们用 Rao-Blackwell 定理求 p

的改进的无偏估计量。

由于 $T = \sum_{i=1}^n X_i$ 为 p 的充分统计量，由于 X_1 只取 0 和 1 两个值，故

$$\begin{aligned} E[X_1 | T = t] &= P(X_1 = 1 | T = t) \\ &= \frac{P(X_1 = 1, T = t)}{P(T = t)} \\ &= \frac{P(X_1 = 1, X_2 + X_3 + \cdots + X_n = t - 1)}{P(T = t)} \\ &= \frac{P(X_1 = 1)P(X_2 + X_3 + \cdots + X_n = t - 1)}{P(T = t)} \\ &= \frac{p C_{n-1}^{t-1} p^{t-1} (1-p)^{n-1-(t-1)}}{C_n^t p^t (1-p)^{n-t}} \\ &= \frac{t}{n} \end{aligned}$$

故由 Rao-Blackwell 定理知

$$E[X_1 | T] = \frac{T}{n} (= \bar{X}) \text{ 是 } p \text{ 的改进的无偏估计量。}$$

注：利用对称性直接可知， $E[X_1 | T] = E[X_1 | \sum_{i=1}^n X_i] = \frac{\sum_{i=1}^n X_i}{n}$ 。

★ UMVUE 的一个判别准则：零无偏估计定理

如果 UMVUE 存在，则由 Rao-Blackwell 定理的推论知，它一定是充分统计量的函数。

零无偏估计量是指期望为 0 的统计量。

定理（零无偏估计定理）如果 $\hat{\theta}$ 是 θ 的方差有限的无偏估计量，且对任何零无偏估计量 $\varphi = \varphi(X_1, \cdots, X_n)$ ，都有

$$\text{Cov}_{\theta}(\hat{\theta}, \varphi) = 0, \forall \theta \in \Theta$$

则 $\hat{\theta}$ 是 θ 的 UMVUE。

证明：对 θ 的任意一个无偏估计量 $\tilde{\theta}$ ，显然 $\varphi \triangleq \tilde{\theta} - \hat{\theta}$ 为零无偏估计量，且

$$D(\tilde{\theta}) = D(\hat{\theta} + \varphi) = D(\hat{\theta}) + D(\varphi) + 2\text{Cov}(\hat{\theta}, \varphi) \\ = D(\hat{\theta}) + D(\varphi) \geq D(\hat{\theta}), \forall \theta \in \Theta$$

例：设 $X \sim E(\frac{1}{\theta})$ ，参数 θ 未知， $X_1, X_2, \dots, X_n$ 是其容量为 n 的样本。则 $\bar{X}$ 为 θ 的

UMVUE。

解：由因子分解定理， $T = T(X_1, X_2, \dots, X_n) = \sum_{i=1}^n X_i$ 为 θ 的充分统计量，

$\bar{X} = \frac{T}{n}$ 为 θ 的无偏估计量。设任何零无偏估计量 $\varphi = \varphi(X_1, \dots, X_n)$ ，由于

$$E\varphi = \int_0^\infty \cdots \int_0^\infty \varphi(x_1, \dots, x_n) \prod_{i=1}^n \left[\frac{e^{-\frac{x_i}{\theta}}}{\theta} \right] dx_1 \cdots dx_n = 0$$

$$\text{即 } \int_0^\infty \cdots \int_0^\infty \varphi(x_1, \dots, x_n) e^{-\sum_{i=1}^n \frac{x_i}{\theta}} dx_1 \cdots dx_n = 0$$

两边对 θ 求导得

$$\int_0^\infty \cdots \int_0^\infty \frac{n\bar{X}}{\theta^2} \varphi(x_1, \dots, x_n) e^{-\sum_{i=1}^n \frac{x_i}{\theta}} dx_1 \cdots dx_n = 0$$

即 $E(\bar{X}\varphi) = 0$ ，即 $\text{Cov}(\bar{X}, \varphi) = 0$ ，故 $\bar{X}$ 为 θ 的 **UMVUE**。

Cremer-Rao 不等式和有效估计

★ Fisher 信息量:

设总体的密度函数 (或 pmf) $f(x; \theta)$, $\theta \in \Theta$ 满足下列条件:

- 1) 参数空间 Θ 是直线上的一个开区间;
- 2) 支撑 $S = \{x: f(x; \theta) > 0\}$ 与 θ 无关;
- 3) 导数 $\frac{\partial}{\partial \theta} f(x; \theta)$ 对一切 $\theta \in \Theta$ 都存在;
- 4) 对 $f(x; \theta)$, 积分与微分运算可交换次序, 即

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} f(x; \theta) dx = \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} f(x; \theta) dx,$$

- 5) 期望 $I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln f(X; \theta) \right]^2$ 存在。

则称该期望 $I(\theta)$ 为总体分布的 **Fisher** 信息量。

注: 如果二阶导数对一切 $\theta \in \Theta$ 都存在, 则 $I(\theta)$ 还可以用下式计算

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right]$$

★ Cremer-Rao 不等式

设 $X_1, X_2, \dots, X_n$ 为取自具有 pdf (或 pmf) $f(x; \theta)$, $\theta \in \Theta = \{\theta: a < \theta < b\}$ 的总体 X 的一个样本, a, b 为已知常数, a 可以取 $-\infty$, b 可以取 $+\infty$ 。又 $\eta = \eta(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的一个无偏估计, 且满足正则条件:

- 1) 集合 $\{x: f(x; \theta) > 0\}$ 与 θ 无关;
- 2) $g'(\theta)$ 与 $\frac{\partial f(x; \theta)}{\partial \theta}$ 存在, 且对一切 $\theta \in \Theta$,

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial f(x; \theta)}{\partial \theta} dx,$$

$$\begin{aligned} & \frac{\partial}{\partial \theta} \int \int \cdots \int \eta(x_1, x_2, \dots, x_n) f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) dx_1 dx_2 \cdots dx_n \\ &= \int \int \cdots \int \eta(x_1, x_2, \dots, x_n) \frac{\partial}{\partial \theta} \left[\prod_{i=1}^n f(x_i; \theta) \right] dx_1 dx_2 \cdots dx_n; \end{aligned}$$

$$3) \text{ 令 } I(\theta) = E_{\theta} \left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 > 0,$$

$$\text{则 } D_{\theta} \eta \geq \frac{[g'(\theta)]^2}{nI(\theta)} \quad (*)$$

并且存在一个有可能依赖于 θ 但不依赖于 $X_1, X_2, \dots, X_n$ 的数 K , 使得等式

$$\sum_{i=1}^n \frac{\partial \ln f(X_i; \theta)}{\partial \theta} = K(\eta - g(\theta)) \text{ 以概率 } 1 \text{ 成立, 以上这个条件为式 } (*) \text{ 中等式成}$$

立的充要条件。特别地当 $g(\theta) = \theta$ 时, 不等式 $(*)$ 化为

$$D_{\theta} \eta \geq \frac{1}{nI(\theta)}.$$

[注]1. 若 ξ 是离散型随机变量, $f(x; \theta)$ 则表示为 $P(\xi = x; \theta)$, 相应的积分号改为求和号。

2. 在使用 R-C 不等式时可不必验证 2) 是否成立, 因为在一般情况下, 当 1) 成立时 2) 自动满足。

3. 满足 1)、2) 假定的估计量称为正则估计。

4. R-C 下界 $\frac{[g'(\theta)]^2}{nI(\theta)}$ 不是所有无偏估计的下界, 而是无偏估计类中一个子

集——正则无偏估计的方差下界。

5. R-C 的重要作用——达到 R-C 下界的估计量一定是 UMVUE. 反之不然。即 UMVUE 不一定达到 R-C 下界。

6. $I(\theta)$ 信息量的意义

当 $D_{\theta} \eta = \frac{1}{nI(\theta)}$ $I(\theta)$ 越大, $D(\eta)$ 越小估计精度高, 而 $I(\theta)$ 大, 则认为模型本身所含的信息量较多, 或者说 θ 易认识, 所以可视 $I(\theta)$ 反应了模型中含有信息的量。

7. 若 C-R 不等式的等号成立 (达到 C-R 下界), 则称 $\eta = \eta(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的有效估计, 有效估计一定是 UMVUE。

8. 设 T_1, T_2 为 θ 的两个无偏估计, 其方差均存在, 称 $eff_{\theta}(T_1 | T_2) \triangleq \frac{D_{\theta}(T_2)}{D_{\theta}(T_1)}$

为 T_1 关于 T_2 的效率, 称 T_1 比 T_2 有效, 若 $eff_{\theta}(T_1 | T_2) > 1$ 。

若 T 为 θ 的有效估计 (即 $D_{\theta}(T) = \frac{1}{nI(\theta)}$), 则定义 θ 的无偏估计 T_1 的效率为

$$eff_{\theta}(T_1) = eff_{\theta}(T_1 | T) = \frac{D_{\theta}(T)}{D_{\theta}(T_1)} = \frac{1}{nI(\theta)D_{\theta}(T_1)}$$

故有效估计的效率为 1, 任一无偏估计的效率不超过 1。

例 设样本 $X_1, X_2, \dots, X_n$ 是来自 $B(1, p)$, 求 p 的 UMVUE。

解: 设总体分布为 $f(x; p) = p^x(1-p)^{1-x}$, $x=0, 1, 0 < p < 1$ 。

易证 $\{f(x; p) | p \in p(0, 1)\}$ 满足正则条件, 因为

$$I(p) = E_p \left[\frac{\partial}{\partial p} \ln f(X, p) \right]^2 = E_p \left[\frac{X-p}{p(1-p)} \right]^2 = \frac{1}{p^2(1-p)^2} E_p (X-p)^2 = \frac{1}{p(1-p)},$$

故 $\frac{1}{nI(p)} = \frac{p(1-p)}{n}$ 为 p 的无偏估计的 C-R 下界;

$$\bar{X} \text{ 作为 } p \text{ 的无偏估计, 有: } D_p(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n D_p(X_i) = \frac{1}{n^2} np(1-p) = \frac{p(1-p)}{n},$$

$\bar{X}$ 达到了 C-R 下界, 故 $\bar{X}$ 为 p 的 UMVUE。

例 设总体 X 的密度函数为 $f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0; \\ 0, & x \leq 0; \end{cases}$ 未知参数 $\lambda > 0$, 总体的一个

样本为 $(X_1, X_2, \dots, X_n)$, 证明 $\bar{X}$ 是 $\frac{1}{\lambda}$ 的一个 UMVUE。

证明: 由指数分布的总体满足正则条件可得:

$$I(\lambda) = -E \left[\frac{\partial^2}{\partial \lambda^2} \ln f(X; \lambda) \right] = -E \left(\frac{-1}{\lambda^2} \right) = \frac{1}{\lambda^2},$$

$$\frac{\left[\left(\frac{1}{\lambda} \right)' \right]^2}{nI(\lambda)} = \frac{\left[\frac{-1}{\lambda^2} \right]^2}{n \frac{1}{\lambda^2}} = \frac{1}{n\lambda^2} \text{ 为 } \frac{1}{\lambda} \text{ 的无偏估计方差的 C-R 下界;}$$

另一方面 $E(\bar{X}) = \frac{1}{\lambda}$, $V_{ar}(\bar{X}) = \frac{1}{n\lambda^2}$; 即 $\bar{X}$ 的方差达到了 C-R 下界,

故 $\bar{X}$ 是 $\frac{1}{\lambda}$ 的一个 UMVUE。

完备统计量与 Lemann-Scheffe 定理

定义：称分布族 $\{f_\theta(x): \theta \in \Theta\}$ 是完备的，若 $\forall \theta \in \Theta$,

$$E_\theta(g(X)) = 0 \Rightarrow P_\theta(g(X) = 0) = 1$$

定义：称统计量 $T = T(X_1, X_2, \dots, X_n)$ 为完备的，若 T 的分布族是完备的。

注：完备分布族条件下， $E_\theta(g_1(X)) = E_\theta(g_2(X))$ ，则有

$$P_\theta(g_1(X) = g_2(X)) = 1$$

例：二项分布族 $\{B(n, p): 0 < p < 1\}$ (n 已知) 是完备分布族。

证明：若 $E_p(g(X)) = \sum_{k=0}^n g(k) C_n^k p^k (1-p)^{n-k} = 0, \quad 0 < p < 1$

$$\text{则 } \sum_{k=0}^n g(k) C_n^k \left(\frac{p}{1-p}\right)^k = 0, \quad 0 < p < 1$$

等式左面是 $\frac{p}{1-p}$ 的 n 次多项式，故 $g(k) = 0, k = 0, 1, 2, \dots, n$ ，证毕。

$$\star \prod_{i=1}^n f(x_i; \theta) = C(\theta) h(x_1, x_2, \dots, x_n) \exp\{b(\theta) T(x_1, x_2, \dots, x_n)\}$$

则 $T = T(x_1, x_2, \dots, x_n)$ 是 θ 的充分完备统计量

$$\star \prod_{i=1}^n f(x_i; \theta) = C(\theta) h(x_1, x_2, \dots, x_n) \exp\{b_1(\theta) T_1(x_1, x_2, \dots, x_n) + b_2(\theta) T_2(x_1, x_2, \dots, x_n)\}$$

则 (T_1, T_2) 是 $\theta = (\theta_1, \theta_2)$ 的充分完备统计量

★ **Lehmann-Scheffe 定理：**

若 T 是 θ 的充分完备统计量， $\varphi(X_1, \dots, X_n)$ 是 $g(\theta)$ 的一个无偏估计，则

$$E[\varphi(X_1, \dots, X_n) | T] \text{ 为 } g(\theta) \text{ 的惟一的 UMVUE}$$

★ **UMVUE 的求解步骤：**

① 求出参数 θ 的充分完备统计量 T

② 求出 $ET = g(\theta)$ ，则 $\theta = g^{-1}(T)$ 是 θ 的一个无偏估计

或求出一个无偏估计，然后改写成用 T 表示的函数

③ 综合， $E[g^{-1}(T)|T] = g^{-1}(T)$ 是 θ 的 **UMVUE**

或者：求出 θ 的矩估计或 **ML** 估计，再求效率，为 1 则必为 **UMVUE**

例：设样本 $X_1, X_2, \dots, X_n$ 是来自 $B(1, p)$ ，求 p 的 **UMVUE**

解：（1）由上例知， $T = \sum_{i=1}^n X_i \sim B(n, p)$ 为充分完备统计量（也是指数族分布），且 X_1 为 p 的无偏估计。由 **Lehmann-Scheffe** 定理， p 的 **UMVUE** 为

$$E(X_1 | T) = E(X_1 | \sum_{i=1}^n X_i) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

例：设样本 $X_1, X_2, \dots, X_n$ 是来自 $N(\theta, 1)$ ，求 θ 的 **UMVUE**

解： $T = \bar{X} \sim N(\theta, 1/n)$ 是充分完备统计量（指数族分布），且 X_1 为 θ 的无偏估计。由 **Lehmann-Scheffe** 定理， θ 的 **UMVUE** 为 $E(X_1 | T)$ 。

由于 $\begin{pmatrix} X_1 \\ \bar{X} \end{pmatrix} \sim N\left(\begin{pmatrix} \theta \\ \theta \end{pmatrix}, \begin{pmatrix} 1 & \frac{1}{n} \\ \frac{1}{n} & \frac{1}{n} \end{pmatrix}\right)$ ，故

$$E(X_1 | T) = E(X_1 | \bar{X}) = \theta + \frac{\text{Cov}(X_1, \bar{X})}{D\bar{X}}(\bar{X} - \theta)$$

$$= \theta + (\bar{X} - \theta) = \bar{X}$$

即 $\bar{X}$ 为 θ 的 **UMVUE**。