

第 14 周讲稿 (1) Bayes 估计

在统计学中有两个大的学派：频率学派（经典学派）和 Bayes 学派

1. 统计推断的基础

经典统计使用到两种信息：总体信息和样本信息；

Bayes 统计认为，除了上述两种信息以外，统计推断还应该使用第三种信息：先验信息。

Bayes 统计的基本观点是：任一未知量 θ 都可看作随机变量，可用一个概率分布去描述，这个分布称为先验分布；在获得样本之后，总体分布、样本与先验分布通过 Bayes 公式结合起来得到一个关于未知量 θ 新的分布——后验分布；任何关于 θ 的统计推断都应该基于 θ 的后验分布进行。

2. Bayes 公式的密度函数形式

(1) 总体依赖于参数 θ 的概率函数在经典统计中记为 $f(x; \theta)$ ，它表示参数空间 Θ 中不同的 θ 对应不同的分布。在 Bayes 统计中应记为 $f(x; \theta)$ ，它表示在 θ 取某个给随机变量定值时总体的条件概率函数。

(2) 根据参数 θ 的先验信息确定先验分布 $\pi(\theta)$ 。

(3) 从 Bayes 观点看，样本 $X = (x_1, \dots, x_n)$ 的产生要分两步进行，

首先设想从先验分布 $\pi(\theta)$ 产生一个样本 θ_0 ；

其次从 $f(x | \theta_0)$ 中产生一组样本。这时样本 $X = (x_1, \dots, x_n)$ 的联合条件概率函数为

$$f(x | \theta_0) = f(x_1, \dots, x_n | \theta_0) = \prod_{i=1}^n f(x_i | \theta_0),$$

这个分布综合了总体信息和样本信息。

(4) 由于 θ_0 是设想出来的，仍然是未知的，它是按先验分布 $\pi(\theta)$ 产生的。为把先验信息综合进去，不能只考虑 θ_0 ，对 θ 的其他值发生的可能性也要加以考虑，故要用 $\pi(\theta)$ 进行综合。这样一来，样本 X 和参数 θ 的联合分布为

$$h(X, \theta) = \pi(\theta | X) m(X)$$

这个联合分布把总体信息、样本信息和先验信息三张可用信息都综合进去了。

(5) 我们的目的是要对未知参数 θ 作统计推断。在没有样本信息时，我们只能依据先验分布对 θ 作出推断。在有了样本观察值 $X = (x_1, \dots, x_n)$ 之后，我们应依据 $h(X, \theta)$ 对 θ 作出推断。若把 $h(X, \theta)$ 作如下分解：

$$h(X, \theta) = \pi(\theta | X) m(X)$$

其中 $m(X)$ 是 X 的边际概率函数, 即

$$m(X) = \int_{\Theta} h(X, \theta) d\theta = \int_{\Theta} f(X | \theta) \pi(\theta) d\theta,$$

它与 θ 无关, 或者说 $m(X)$ 中不含 θ 的任何信息. 因此能用来对 θ 作出推断的仅是条件分布

$\pi(\theta | X)$, 它的计算公式是

$$\pi(\theta | X) = \frac{h(X, \theta)}{m(X)} = \frac{f(X | \theta) \pi(\theta)}{\int_{\Theta} f(X | \theta) \pi(\theta) d\theta}$$

$$\pi(\theta | X) \propto f(X | \theta) \pi(\theta)$$

这个条件分布称为 θ 的后验分布, 它集中了总体、样本和先验中有关 θ 的一切信息, 用总体和样本对先验分布 $\pi(\theta)$ 作调整的结果, 它要比 $\pi(\theta)$ 更接近 θ 的实际情况.

3. Bayes 估计

由后验分布 $\pi(\theta | X)$ 估计 θ 有三种常用的方法:

- 使用后验分布的密度函数最大值做为 θ 的点估计的最大后验估计;
- 使用后验分布的中位数作为 θ 的点估计的后验中位数估计;
- 使用后验分布的均值作为 θ 的点估计的后验期望估计.

用的最多的是后验期望估计, 它一般也简称为 Bayes 估计, 记为 $\hat{\theta}_B$.

例 1 设某事件 A 在一次试验中发生的概率为 θ , 为估计 θ , 对试验进行了 n 次独立观测, 其中事件 A 发生了 X 次, 显然 $X | \theta \sim b(n, \theta)$, 即

$$P(X = x | \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n,$$

假若我们在试验前对事件 A 没有什么了解, 就使用均匀分布 $U(0, 1)$ 作为 θ 的先验分布,

先写出 X 和 θ 的联合分布 $h(X, \theta) = \pi(\theta | X) m(X)$

$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n, \quad 0 < \theta < 1,$$

$$\pi(\theta | X) \propto \theta^{(x+1)-1} (1 - \theta)^{(n-x+1)-1}, \quad 0 < \theta < 1.$$

$$\theta | X \sim \text{Beta}(x+1, n-x+1)$$

详细过程: X 的边际概率函数

$$m(x) = \binom{n}{x} \int_0^1 \theta^x (1-\theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)},$$

故 θ 的后验分布为

$$\pi(\theta | X) = \frac{h(X, \theta)}{m(X)} = \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)} \theta^{(x+1)-1} (1-\theta)^{(n-x+1)-1}, \quad 0 < \theta < 1.$$

由于 $\theta | x \sim Be(x+1, n-x+1)$, 其后验期望估计为

$$\hat{\theta}_B = E(\theta | x) = \frac{x+1}{n+2}.$$

注: 假如不用先验信息, 只用总体信息和样本信息, 那么事件 A 发生的概率的最大似然估计为

$$\hat{\theta}_M = \frac{x}{n},$$

它与 Bayes 估计是不同的两个估计. 某些场合, Bayes 估计要比最大似然估计更合理一点.

例 2 设 $x_1, \dots, x_n$ 是来自正态分布 $N(\mu, \sigma_0^2)$ 的一个样本, 其中 σ_0^2 已知, μ 未知, 假设 μ 的先验分布亦为 $N(\theta, \tau^2)$, 其中先验均值 θ 和先验方差 τ^2 均已知, 试求 μ 的 Bayes 估计。

解: 样本 X 的分布和 μ 的先验分布分别为

$$f(X | \mu) = (2\pi\sigma_0^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

$$\pi(\mu) = (2\pi\tau^2)^{-1/2} \exp\left\{-\frac{1}{2\tau^2} (\mu - \theta)^2\right\}$$

由此可以写出 X 与 μ 的联合分布

$$h(X, \mu) = k_1 \cdot \exp\left\{-\frac{1}{2} \left[\frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{\tau^2} \right]\right\}$$

其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $k_1 = (2\pi)^{-(n+1)/2} \tau^{-1} \sigma_0^{-n}$ 。若记

$$A = \frac{n}{\sigma_0^2} + \frac{1}{\tau^2}, \quad B = \frac{n\bar{x}}{\sigma_0^2} + \frac{\theta}{\tau^2}, \quad C = \frac{\sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\theta^2}{\tau^2}$$

则有

$$\begin{aligned}
 h(X, \mu) &= k_1 \exp \left\{ -\frac{1}{2} [A\mu^2 - 2B\mu + C] \right\} \\
 &= k_1 \exp \left\{ -\frac{(\mu - B/A)^2}{2/A} - \frac{1}{2} \left(C - \frac{B^2}{A} \right) \right\}
 \end{aligned}$$

注意到 A, B, C 均与 μ 无关, 由此容易算得样本的边际密度函数

$$m(X) = \int_{-\infty}^{+\infty} h(X, \mu) d\mu = k_1 \exp \left\{ -\frac{1}{2} \left(C - \frac{B^2}{A} \right) \right\} (2\pi/A)^{1/2}$$

应用 Bayes 公式即可得到后验分布

$$\pi(\mu|X) = \frac{h(X, \mu)}{m(X)} = (2\pi/A)^{1/2} \exp \left\{ -\frac{1}{2/A} (\mu - B/A)^2 \right\}$$

这说明在样本给定后, μ 的后验分布为 $N(B/A, 1/A)$, 即

$$\mu|M \sim N \left(\frac{n\bar{x}\sigma_0^{-2} + \theta\tau^{-2}}{n\sigma_0^{-2} + \tau^{-2}}, \frac{1}{n\sigma_0^{-2} + \tau^{-2}} \right)$$

后验均值即为其 Bayes 估计:

$$\hat{\mu} = \frac{n/\sigma_0^2}{n/\sigma_0^2 + 1/\tau^2} \bar{x} + \frac{1/\tau^2}{n/\sigma_0^2 + 1/\tau^2} \theta$$

它是样本均值 $\bar{x}$ 与先验均值 θ 的加权平均。当总体方差 σ_0^2 较小或样本量 n 较大时, 样本均值 $\bar{x}$ 的权重较大; 当先验方差 τ^2 较小时, 先验均值 θ 的权重较大, 这一综合很符合人们的经验, 也是可以接受的。

例 随机变量 $X \sim Ge(p)$, 参数 p 的先验分布为 $U(0,1)$

- (1) 若只对 X 做一次观察, 其观测值为 3, 求 p 的后验期望估计;
- (2) 若对 X 做三次观察, 其观测值为 3, 2, 5, 求 p 的后验期望估计。

解: 由题意可知 $\pi(p) = 1, 0 < p < 1$

设 $X_1, X_2, \dots, X_n$ 是从随机变量 X 中抽取的随机样本, 则

$$\begin{aligned}
 f(x_1, \dots, x_n|p) &= \prod_{i=1}^n P(X = x_i|p) = \prod_{i=1}^n [(1-p)^{x_i-1} p] \\
 &= p^n (1-p)^{\sum_{i=1}^n x_i - n}, x_i = 1, 2, \dots
 \end{aligned}$$

从而有 $\pi(p|x) \propto f(x|p) \bullet \pi(p) \propto p^n (1-p)^{\sum_{i=1}^n x_i - n}, 0 < p < 1$, 这里 $x = (x_1, x_2, \dots, x_n)$ 。

所以 $p|x \sim \text{Beta}(n+1, \sum_{i=1}^n x_i - n + 1)$

(1) 由题意可知 $n=1, x=3$

$$\therefore p|x \sim \text{Beta}(2, 3)$$

$$\therefore \hat{p}_{BE} = \frac{2}{2+3} = \frac{2}{5}$$

(2) 由题意可知 $n=3, x_1=3, x_2=2, x_3=5$

$$\therefore p|x \sim \text{Beta}(4, 8)$$

$$\therefore \hat{p}_{BE} = \frac{4}{4+8} = \frac{1}{3}$$

4 共轭先验分布

定义：设 θ 是总体参数， $\pi(\theta)$ 是其先验分布，若对任意的样本观测值得到的后验分布 $\pi(\theta|X)$ 与 $\pi(\theta)$ 属于同一个分布族，则称该分布族是 θ 的共轭先验分布（族）。

在例 1 中，由于 $U(0,1) = \text{Beta}(1,1)$ ，其对应的后验分布则是 $\text{Beta}(x+1, n-x+1)$ 。

更一般地，设 θ 的先验分布是 $\text{Be}(a, b), a > 0, b > 0$ ， a, b 均已知，则由 Bayes 公式可以求出后验分布为 $\text{Be}(x+a, n-x+b)$ ，这说明 Beta 分布是伯努利试验中成功概率的共轭先验分布。

在例 2 中，在方差已知时正态总体均值的共轭先验分布是正态分布。

共轭先验分布列表

总 体 分 布 $f(x \theta)$	先验分布 $\pi(\theta)$	后验分布 $\pi(\theta x)$
$N(\mu, \sigma^2)$, σ^2 已知。 $\theta = \mu$	$\pi(\mu) \leftrightarrow N(\alpha, \tau^2)$	$N(\frac{n\bar{x}\sigma^{-2} + \alpha\tau^{-2}}{n\sigma^{-2} + \tau^{-2}}, \frac{1}{n\sigma^{-2} + \tau^{-2}})$
$\Gamma(\alpha, \beta)$, α 已 知, $\theta = \beta$	$\pi(\beta) \leftrightarrow \Gamma(\alpha_0, \beta_0)$	$\Gamma(\alpha_0 + \alpha n, \beta_0 + \sum_{i=1}^n x_i)$
$B(n_0, p)$; $\theta = p$	$\pi(p) \leftrightarrow \text{Beta}(a, b)$	$\text{Beta}(a + \sum_{i=1}^n x_i, b + nn_0 - \sum_{i=1}^n x_i)$
$P(\lambda)$; $\theta = \lambda$	$\pi(\lambda) \leftrightarrow \Gamma(\alpha, \beta)$	$\Gamma(\alpha + \sum_{i=1}^n x_i, \beta + n)$
$NB(r, p)$; $\theta = p$	$\pi(p) \leftrightarrow \text{Beta}(a, b)$	$\text{Beta}(a + nr, b + \sum_{i=1}^n x_i - nr)$
$N(\mu, \sigma^2)$, μ 已 知; $\theta = \sigma^2$	$\pi(\sigma^2) \leftrightarrow \text{IGa}(\alpha, \lambda)$	$\text{IGa}(\alpha + \frac{n}{2}, \lambda + \sum_{i=1}^n (x_i - \mu)^2)$

$X \sim \text{IGa}(\alpha, \lambda)$ (逆 Gamma 分布: $\xi \sim \Gamma(\alpha, \lambda) \Leftrightarrow \xi^{-1} \sim \text{IGa}(\alpha, \lambda)$), 如

果它的密度函数为 $f(x; \alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} (\frac{1}{x})^{\alpha+1} e^{-\frac{\lambda}{x}}, x > 0$